

Python Insights - Analisando Dados com Python

Case - Cancelamento de Clientes

Você foi contratado por uma empresa com mais de 800 mil clientes para um projeto de Dados. Recentemente a empresa percebeu que da sua base total de clientes, a maioria são clientes inativos, ou seja, que já cancelaram o serviço.

Precisando melhorar seus resultados ela quer conseguir entender os principais motivos desses cancelamentos e quais as ações mais eficientes para reduzir esse número.

Base de dados e arquivos:

https://drive.google.com/drive/folders/1uDesZePdkhiraJmiyeZ-w5tfc8XsNYFZ?usp=drive_link

```
In [1]: # Passo a passo
        # Passo 1: Importar a base de dados
        # Passo 2: Visualizar os dados (entender a base + identificar problema)
        # Passo 3: Descartar os dados que não são úteis para minha resolução
        # Passo 4: Analisar os dados depois de limpos e começar o raciocínio
        # Passo 5: Montar os gráficos para vê o que impacta no cancelamento
```

```
In [2]: # Passo 1: Importar a base de dados

import pandas as pd    # importando a biblioteca pandas

tabela = pd.read_csv('cancelamentos.csv') # importando os dados

# Passo 2: Visualizar os dados (entender a base + identificar problema)
display(tabela)
```

	CustomerID	idade	sexo	tempo_como_cliente	frequencia_uso	lig
0	2.0	30.0	Female	39.0	14.0	
1	3.0	65.0	Female	49.0	1.0	
2	4.0	55.0	Female	14.0	4.0	
3	5.0	58.0	Male	38.0	21.0	
4	6.0	23.0	Male	32.0	20.0	
...
881661	449995.0	42.0	Male	54.0	15.0	
881662	449996.0	25.0	Female	8.0	13.0	
881663	449997.0	26.0	Male	35.0	27.0	
881664	449998.0	28.0	Male	55.0	14.0	
881665	449999.0	31.0	Male	48.0	20.0	

881666 rows x 12 columns

```
In [3]: # Passo 3: Descartar os dados que não são úteis para minha resolução
# CustomerID não interfere na taxa de cancelamento, logo não será necessário
tabela = tabela.drop(columns='CustomerID')

# verificar se existe dados vazios
display(tabela.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 881666 entries, 0 to 881665
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   idade                                881664 non-null  float64
1   sexo                                881664 non-null  object
2   tempo_como_cliente                  881663 non-null  float64
3   frequencia_uso                      881663 non-null  float64
4   ligacoes_callcenter                881664 non-null  float64
5   dias_atraso                        881664 non-null  float64
6   assinatura                          881661 non-null  object
7   duracao_contrato                   881663 non-null  object
8   total_gasto                        881664 non-null  float64
9   meses_ultima_interacao             881664 non-null  float64
10  cancelou                           881664 non-null  float64
dtypes: float64(8), object(3)
memory usage: 74.0+ MB
None
```

```
In [4]: # visualizando quais são os dados que possuem valores vazios
display(tabela[tabela.isna().any(axis=1)])
```

	idade	sexo	tempo_como_cliente	frequencia_uso	ligacoes_callcen
11	52.0	Female	21.0	6.0	
14	24.0	Male	4.0	9.0	
17	47.0	Male	41.0	NaN	
18	24.0	Male	44.0	13.0	
23	27.0	Female	NaN	8.0	
199295	NaN	NaN	NaN	NaN	N
640128	NaN	NaN	NaN	NaN	N

```
In [5]: # excluir da tabela os valores vazios, já que são poucos valores
tabela = tabela.dropna()

# tabela atualizada sem nenhum valor vazio
display(tabela.info())
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 881659 entries, 0 to 881665
Data columns (total 11 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   idade                                881659 non-null  float64
1   sexo                                881659 non-null  object
2   tempo_como_cliente                  881659 non-null  float64
3   frequencia_uso                     881659 non-null  float64
4   ligacoes_callcenter               881659 non-null  float64
5   dias_atraso                       881659 non-null  float64
6   assinatura                         881659 non-null  object
7   duracao_contrato                   881659 non-null  object
8   total_gasto                       881659 non-null  float64
9   meses_ultima_interacao             881659 non-null  float64
10  cancelou                          881659 non-null  float64
dtypes: float64(8), object(3)
memory usage: 80.7+ MB
None
```

```
In [6]: # Passo 4: Analisar os dados depois de limpos e começar o raciocínio
display(tabela['cancelou'].value_counts()) # visualizar quantos cancelou

display(tabela['cancelou'].value_counts(normalize=True).map("{:.1%}"))
```

```
cancelou
1.0    499993
0.0    381666
Name: count, dtype: int64

cancelou
1.0    56.7%
0.0    43.3%
Name: proportion, dtype: object
```

```
In [7]: # Passo 5: Montar os gráficos para vê o que impacta no cancelamento
import plotly.express as px
```

```
# montar os gráficos em dois passos: criar o gráfico e exibir o gráfico
# criar o gráfico
grafico = px.histogram(tabela, x='duracao_contrato', color='cancelou')
# montar o gráfico
grafico.show()
```

```
In [8]: # criar os graficos relacionando com todos os dados

for coluna in tabela.columns:
    grafico = px.histogram(tabela, x=coluna, color='cancelou', text=coluna)
    grafico.show()
```

```
In [9]: # Levantar os pontos chaves da observação:
        # P1: Pessoas com plano mensal cancelam

        # P2: dias_atraso maior que 20 gera cancelamento

        # P3: ligacoes_callcenter mais de 4x gera cancelamento
```

```
In [10]: # visualizar como ficaria a taxa de cancelamento se esses problemas
         # resolvendo o P1:
tabela = tabela[tabela['duracao_contrato'] != 'Monthly'] # taxa caiu

# resolvendo P2:
tabela = tabela[tabela['dias_atraso'] <= 20] # taxa caiu para 35%

# resolvendo P3:
tabela = tabela[tabela['ligacoes_callcenter'] <= 4] # taxa caiu para 18.4%

display(tabela['cancelou'].value_counts(normalize=True).map("{:.1%}"))

cancelou
0.0    81.6%
1.0    18.4%
Name: proportion, dtype: object
```